모델 비교표 (팀 결과 취합)

MAT4091 Fashion Category Tagging · 1번(평가·진단) · 2026-11-08 · 각 팀원 브랜치의 결과 파일을 모은 것이다. 제가 다시 학습한 값은 없다. 클래스별 파일이 있는 모델은 Macro F1(val 11개, holdout 6개)과 Micro F1(4개 모델)을 다시 계산해 보고서 값과 모두 일치했다. 그 외 값(고해상도 5번 행, TTA·조정 임계값 행 등)은 보고서 값을 그대로 옮겼다.

1. 한눈에 보기

- **해상도가 가장 큰 차이를 만들었다.** val Macro F1이 정사각형 384 기준선 0.661 → 고해상도 384 고정 0.695 → 고해상도 800/1333 0.728로 올랐다. 작은 액세서리 그룹 평균 F1은 0.663 → 0.725이다 (watch 0.60 → 0.75, glasses 0.87 → 0.94, belt 0.66 → 0.72).
- **외부 데이터 3,458장은 낮은 해상도 모델에서 뚜렷한 이득이 없었다.** ConvNeXt는 val Macro 0.653 → 0.643(Micro 0.819 → 0.825), EVA02는 기준선 0.632 → 0.595로 내려갔다(EVA 기준선은 flip만 쓰고 V2는 색 증강·가중 샘플링도 바뀌어 통제 비교는 아니다). 고해상도 모델에는 아직 적용하지 않았다.
- **BCE와 ASL은 우열을 가리기 어렵다.** 임계값 0.5에서 val Macro 0.736 vs 0.740(4번 보고서의 95% 구간이 0을 포함), 임계값·TTA를 조정하면 0.759 vs 0.753이다. 다만 최적 임계값이 BCE 0.15~0.25, ASL 0.55~0.65로 크게 달라서 임계값을 같이 정해야 공정한 비교가 된다.
- **증류(Fashionformer 점수)의 이득은 val에서 확인되지 않았다.** BCE+증류는 val Micro 0.876 / Macro 0.738 / Image 0.879, 임계값·TTA를 조정한 BCE는 0.874 / 0.759 / 0.873이다. 헤드(linear_ms + gap·gmp)와 임계값 선택 방식이 달라서 증류만의 효과로 읽을 수는 없다.
- **가장 약한 클래스는 leg warmer, cardigan, jumpsuit, vest, glove, sweater이다.** 모두 val 양성이 21장 이하라서 한두 장에 점수가 크게 바뀐다. 고해상도 모델 4개의 평균 F1: leg warmer 0.17, cardigan 0.40, jumpsuit 0.46, vest 0.52, glove 0.59, sweater 0.60.
- **Fashionformer(참고, 0.705)는 val Macro 기준으로 고해상도 모델과 비슷하거나 낮다.** 다만 vest, sweater 등 겹쳐 입은 옷에서는 아직 앞선다(vest 0.72 vs 0.47).

2. 읽기 전에

- 모든 점수는 **seed 1개**의 단일 학습 결과다. 같은 계열로 알려진 5번 HR(ASL, 0.5)과 4번 C1-ASL의 val Macro가 0.728과 0.740로 0.013 다르다(코드·seed·헤드가 같은지는 확인하지 못했다). **Macro 0.01~0.02 안쪽 차이는 우열로 읽지 않는다.**
- 조건이 다른 행을 바로 비교하지 않는다. **A(정사각형 384/378)**끼리, **B(고해상도 800/1333)**끼리 비교하고, A와 B의 차이는 해상도 효과를 포함한다. 임계값·TTA 열을 꼭 본다.
- val은 팀이 여러 번 보고 설정을 고른 데이터라 비공개 평가보다 낙관적일 수 있다. 선택은 holdout으로 했다고 각 보고서에 적혀 있다.
- **이 표는 Fashionpedia val/holdout 기준이다.** 5번 규칙 문서에 따르면 제공 테스트는 군중 사진이 약 50%이고 이미지당 정답 라벨이 약 9개(train 약 3개)라서 이 점수가 테스트 점수를 대표하지 않는다.
- Fashionformer는 holdout(2,425장)이 학습 데이터에 들어 있어 holdout 점수를 비워 두었다. 제출 후보가 아닌 참고용이다.

3. 실험 목록과 조건

ID	실험	입력	손실	외부 데이터	증류	임계값 / TTA	파라미터	담당
A. 정사각형 384/378 (낮은 해상도)								
S2	ConvNeXt-T 기준선	384² 패딩	BCE	없음	없음	0.5	27.8M	2번
EVA	EVA02-S 기준선	378² 패딩	BCE	없음	없음	0.5	21.8M	3번
EVA+	EVA02-S + wd 제외·drop path·EMA	378² 패딩	BCE	없음	없음	0.5	21.8M	5번
S2-ctl	ConvNeXt-T 공통 증강, 원본만	384² 패딩	BCE	없음	없음	0.5	27.8M	2번
S2-3458	ConvNeXt-T + 외부 3,458장	384² 패딩	Masked BCE	3,458장	없음	0.5	27.8M	2번
EVA-V2	EVA02-S + 외부 3,458장	378² 패딩	Masked BCE	3,458장	없음	0.5	21.8M	3번

B. 고해상도 800/1333 (비율 유지)								
HR-low	ConvNeXt-T 고해상도 레시피, 384 고정	384 비율 유지	ASL	없음	없음	0.5	27.8M	5번
HR	ConvNeXt-T 고해상도 (기본)	800/1333 비율 유지	ASL	없음	없음	0.5	27.8M	5번
HR-tta	위 + 임계값 0.60(3개 0.5) + 반전 TTA	800/1333 비율 유지	ASL	없음	없음	0.60 + TTA	27.8M	5번
C1-BCE	고해상도, BCE	800/1333 비율 유지	BCE	없음	없음	0.5	27.8M	4번
C1-BCE-t	위 + 임계값 0.25 + 반전 TTA	800/1333 비율 유지	BCE	없음	없음	0.25 + TTA	27.8M	4번
C1-ASL	고해상도, ASL	800/1333 비율 유지	ASL	없음	없음	0.5	27.8M	4번
C1-ASL-t	위 + 임계값 0.55 + 반전 TTA	800/1333 비율 유지	ASL	없음	없음	0.55 + TTA	27.8M	4번
KD	고해상도, BCE + Fashionformer 증류	800/1333 비율 유지	BCE + 증류	없음	Fashionformer	0.4(3개 0.5) + TTA	27.9M	4번
R. 참고								
FF	Fashionformer R50 (검출·분할 모델, 참고)	800/1333 비율 유지	검출 손실	없음	-	0.3	44.1M	5번 측정

4. 전체 점수

ID	holdout Micro	Macro	Image	val Micro	Macro	Image	출처
A. 정사각형 384/378 (낮은 해상도)							
S2	0.805	0.707	0.809	0.826	0.661	0.828	results_hires_convnext.md 2장 표
EVA	0.804	0.709	0.805	0.811	0.632	0.816	role3 comparison_summary.csv
EVA+	0.825	0.739	0.825	0.840	0.659	0.841	results_hires_convnext.md 2장 표
S2-ctl	0.805	0.702	0.806	0.819	0.653	0.822	role2 comparison_three_runs.csv
S2-3458	0.809	0.707	0.809	0.825	0.643	0.826	role2 comparison_three_runs.csv
EVA-V2	0.800	0.699	-	0.809	0.595	-	EVA02_V2_RESULTS_ANALYSIS.md, per_class_*.csv
B. 고해상도 800/1333 (비율 유지)							
HR-low	0.833	0.760	0.842	0.834	0.695	0.840	results_hires_convnext.md 1장 표
HR	0.844	0.779	0.847	0.855	0.728	0.859	results_hires_convnext.md 1장 표
HR-tta	0.857	0.791	0.858	0.867	0.744	0.868	results_hires_convnext.md TTA 표
C1-BCE	0.857	0.784	0.852	0.870	0.736	0.867	role4 C1 summary.csv
C1-BCE-t	0.860	0.794	0.858	0.874	0.759	0.873	role4 C1 summary.csv
C1-ASL	0.847	0.783	0.848	0.856	0.740	0.859	role4 C1 summary.csv
C1-ASL-t	0.854	0.784	0.854	0.863	0.753	0.866	role4 C1 summary.csv
KD	0.871	0.799	0.872	0.876	0.738	0.879	role4 BCE KD val_metrics.json
R. 참고							
FF	-	-	-	0.858	0.705	0.861	fashionformer_eval/README.md

Micro / Macro / Image-wise F1. holdout = 모델 선택에 쓴 내부 검증 2,425장, val = 공식 검증 1,158장(보고용). "-"는 해당 보고서에 없는 값이다.

5. 그룹별 평균 F1 (val)

그룹 (클래스 수)	S2	EVA	EVA+	S2-3458	EVA-V2	HR-low	HR	C1-BCE	C1-ASL	KD†	FF†
작은 액세서리 (8)	0.663	0.552	0.573	0.641	0.519	0.643	0.725	0.727	**0.745**	0.774	0.729
상의 (7)	0.585	0.564	0.650	0.592	0.564	0.631	0.667	**0.672**	0.653	0.708	0.714
그 외 (12)	0.703	0.726	0.721	0.674	0.664	0.767	0.765	0.779	**0.788**	0.731	0.683
희귀 (9) — 위 그룹과 겹침	0.459	0.450	0.462	0.449	0.359	0.526	0.562	0.574	**0.597**	0.534	0.484

굵게 = 그룹 안에서 가장 높은 모델. †(FF, KD)는 임계값·TTA 조건이 달라 굵게 표시에서 제외했다. 그룹은 우리의 가설이다. 작은 액세서리·상의·그 외는 서로 겹치지 않고, **희귀(val 양성 30장 미만 9개: sweater, cardigan, vest, jumpsuit, cape, tie, glove, leg warmer, umbrella)는 다른 그룹과 겹쳐 따로 집계**한다. 그 외 12개에는 희귀 4개(jumpsuit · cape · leg warmer · umbrella)가 들어 있어 평균이 낮아진다. 작은 액세서리 = glasses · watch · glove · sock · belt · tie · scarf · headband, head covering, hair accessory / 상의 = shirt, blouse · top, t-shirt, sweatshirt · sweater · cardigan · jacket · vest · coat.

6. 클래스별 val F1

클래스	그룹	희귀	val 양성	S2	EVA	EVA+	S2-3458	EVA-V2	HR-low	HR	C1-BCE	C1-ASL	KD†	FF†
shirt, blouse	상의		102	0.685	0.564	0.670	0.644	0.639	0.719	**0.728**	0.705	0.714	0.742	0.728
top, t-shirt, sweatshirt	상의		463	0.789	0.786	0.828	0.810	0.798	0.822	0.838	**0.845**	0.835	0.857	0.851
sweater	상의	●	21	0.550	0.389	0.595	0.500	0.312	0.509	0.556	**0.636**	0.556	0.732	0.652
cardigan	상의	●	12	0.095	0.162	0.300	0.190	0.143	0.343	**0.500**	0.316	0.438	0.385	0.467
jacket	상의		179	0.782	0.773	**0.809**	0.771	0.734	0.800	0.792	0.796	0.785	0.822	0.792
vest	상의	●	21	0.412	0.556	0.564	0.485	0.595	0.478	0.471	**0.615**	0.458	0.571	0.722
pants	그 외		313	0.886	0.890	0.913	0.903	0.887	0.917	0.916	**0.918**	0.915	0.920	0.896
shorts	그 외		106	0.821	0.817	0.822	0.800	0.783	0.811	0.820	**0.841**	0.839	0.844	0.809
skirt	그 외		162	0.695	0.702	0.762	0.712	0.662	0.724	0.730	**0.763**	0.751	0.756	0.713
coat	상의		103	0.781	0.719	0.784	0.742	0.728	0.747	0.783	**0.792**	0.789	0.844	0.789
dress	그 외		506	0.891	0.898	0.906	0.891	0.893	0.900	0.914	**0.928**	0.914	0.914	0.902
jumpsuit	그 외	●	21	0.400	0.421	0.444	0.323	0.417	0.333	0.480	**0.529**	0.440	0.512	0.340
cape	그 외	●	5	0.571	0.444	0.333	0.333	0.286	0.500	0.727	**0.889**	0.667	0.286	0.000
glasses	작은 액세서리		130	0.866	0.831	0.848	0.849	0.809	0.882	0.944	**0.961**	0.940	0.969	0.950
hat	그 외		74	0.865	0.878	0.878	0.855	0.853	0.901	**0.910**	0.891	0.901	0.931	0.863
headband, head covering, hair accessory	작은 액세서리		105	0.657	0.622	0.703	0.678	0.595	0.726	**0.797**	0.788	0.767	0.827	0.829
tie	작은 액세서리	●	3	0.857	0.500	0.400	**1.000**	0.333	0.667	0.750	0.750	0.750	0.750	0.667
glove	작은 액세서리	●	18	0.500	0.438	0.629	0.462	0.483	0.458	0.571	0.545	**0.667**	0.686	0.537
watch	작은 액세서리		82	0.604	0.531	0.415	0.484	0.460	0.652	0.754	**0.782**	0.770	0.795	0.744
belt	작은 액세서리		159	0.662	0.618	0.610	0.628	0.601	0.670	0.725	**0.761**	0.751	0.758	0.746
leg warmer	그 외	●	7	0.000	0.250	0.000	0.000	0.000	**0.444**	0.000	0.000	0.400	0.000	0.222
tights, stockings	그 외		62	0.752	0.713	**0.872**	0.737	0.734	0.825	0.829	0.833	0.771	0.838	0.818
sock	작은 액세서리		51	0.602	0.442	0.456	0.550	0.477	0.538	**0.626**	0.614	0.606	0.718	0.680
shoe	그 외		804	0.978	0.980	0.981	0.981	0.981	0.978	0.985	**0.986**	0.984	0.988	0.983
bag, wallet	그 외		205	0.831	0.825	0.856	0.805	0.809	0.868	0.873	**0.887**	0.874	0.899	0.901
scarf	작은 액세서리		48	0.557	0.438	0.521	0.480	0.394	0.547	0.629	0.615	**0.708**	0.688	0.681
umbrella	그 외	●	5	0.750	0.889	0.889	0.750	0.667	**1.000**	**1.000**	0.889	**1.000**	0.889	0.750

굵게 = 그 클래스에서 가장 높은 모델(†는 제외). 대부분 임계값 0.5 기준이고, † KD 열만 조정한 임계값 0.4(sweater·leg warmer·umbrella는 0.5) + 반전 TTA, † FF는 Fashionformer 0.3 기준이라 같은 선에서 비교하지 않는다. val 양성이 30장 미만인 클래스는 한두 장으로 F1이 크게 바뀌므로 순위를 그대로 믿지 않는다.

7. 출처

- 2번: `feature/convnext-common3458-results` (comparison_three_runs.csv, per_class_val.csv) · 3번: `feature/eva02-v2-results-analysis` (comparison_summary.csv, results_v2/*) · 4번: `feature/role4-c1-bce-asl-results`, `feature/role4-bce-kd-results`
- 5번: `main`의 experiments/role5_regularization/results_hires_convnext.md, experiments/fashionformer_eval/README.md
- EVA-V2의 holdout Micro(0.800)는 3번의 클래스별 CSV(TP/FP/FN)에서 계산한 값이고, Image-wise F1은 해당 보고서에서 확인하지 못해 비웠다.