모델 제안 통합안

MAT4091 Fashion Category Tagging · 팀 내부 공유용 · 2026-10-31
팀원 제안서 3건과 EDA 보고서를 통합하고 추가 제안을 반영함. 이 문서의 어떤 수치도 F1 실측 결과가 아님.

표기: 추가 기존 팀 제안서에 없던 내용, 정정 문서 간 불일치를 바로잡은 내용

오늘 정할 것 (제안)

1. **기준선**: ConvNeXt-Tiny(ImageNet-22k 사전학습) + GAP + Linear(27) · BCE · 384px · 종횡비 유지 후 패딩 · 좌우 반전만 · 임계값 0.5
2. **Backbone 비교**: ConvNeXt-Tiny vs EVA02-Small. 둘 다 22k 사전학습, 같은 학습 예산
3. **이후 순서**: 손실(BCE→ASL) → 해상도(384→448) → 임계값 → 쿼리 헤드. 한 번에 하나만 변경
4. **ResNet-50 기준선은 생략**하고 ConvNeXt-Tiny를 기준선으로 사용 추가
5. **정할 항목**: 공통 epoch 수, 옵티마이저·학습률, seed, 주요 선택 지표, 조교 질문 발송 담당

1. 과제 조건 요약

- 이미지 속 모든 사람에게서 보이는 27개 카테고리의 합집합을 예측하는 멀티라벨 분류. 대상이 없으면 `[]`
- 쉼표가 들어간 이름(`shirt, blouse` 등)도 하나의 클래스. `categories.txt` 순서와 이름을 그대로 사용
- 최종 추론에 쓰는 모든 모델의 파라미터 합계 **50,000,000개 이하** (앙상블은 전부 합산)
- 모델·임계값은 train/val로만 선택. 공개·비공개 테스트로 학습·튜닝 금지. 오프라인 로컬 실행
- 평가: Micro F1, Macro F1, Image-wise F1. 지표 가중치는 아직 미공지
- 제출: `predict.py` , `model.pt` , `requirements.txt` , `README.md` + 학습 코드 + CVPR 형식 6페이지 논문 + 발표

2. EDA 핵심

항목	Train	Val	모델 설계에 주는 의미
이미지 수	45,622	1,158	Val이 작아 반복 튜닝 시 과적합 위험
이미지당 평균 라벨	2.96	3.25	Sigmoid 기반 멀티라벨 출력 필수
빈 정답 이미지	0	0	`[]` 출력은 구현하되 성능 평가는 불가
shoe 등장률	52.5%	69.4%	Train·Val 분포 차이. 비공개 평가셋도 다를 수 있음
최다/최소 클래스	shoe 23,954 / leg warmer 61 (약 393배)		불균형 대응 손실(ASL 등) 실험 필요
Val 양성 10장 미만	tie 3, cape 5, umbrella 5, leg warmer 7		클래스별 임계값 불안정. 공통 임계값 우선
세로형 이미지	80.0%	79.3%	정사각형 강제 resize vs 패딩 비교 필요
흑백(L) 이미지	186	0	입력 시 RGB 변환 필수

주의 신호: Examples의 라벨 수 추가

EDA 보고서에 따르면 Examples 30장은 이미지당 평균 라벨이 **8.97개**로 train(2.96)·val(3.25)의 약 3배임. 비공개 평가셋이 인물이 많거나 라벨이 많은 이미지 위주일 가능성을 시사함. 이 경우 놓치는 라벨(재현율)이 점수에 더 크게 영향을 줄 수 있음.

단, 이 30장으로 임계값을 맞추거나 학습하면 안 됨. 분포 차이의 근거로만 기록하고, Examples의 허용 용도를 조교에게 확인.

3. 후보 모델과 파라미터 예산

모두 27개 출력 헤드 기준. **실측**은 timm으로 `sum(p.numel())` 을 센 값(EVA02 제안서), **계산**은 공식 수치에서 1000클래스 헤드를 빼고 27클래스 헤드를 더한 값. 최종 해상도에서 반드시 다시 셀 것.

모델	권장 가중치 (timm)	파라미터	50M 대비	역할	제안 출처
ConvNeXt-Tiny	`convnext_tiny.fb_in22k_ft_in1k_384`	27,840,891 (실측)	55.7%	**기준선**, 주력 후보	세 제안서 공통
EVA02-Small	`eva02_small_patch14_336.mim_in22k_ft_in1k`	21,754,395 (실측)	43.5%	**Transformer 주력 비교**	EVA02 제안서
ConvNeXt-Small	`convnext_small.fb_in22k_ft_in1k_384`	약 49.48M (계산)	99.0%	큰 단일 모델 상한 비교	달파 제안서
EfficientNetV2-S	`tf_efficientnetv2_s.in21k_ft_in1k`	약 20.2M (계산)	40.4%	경량 후보, 앙상블 구성원	공통
DINOv2 ViT-S/14	`vit_small_patch14_dinov2.lvd142m`	22,066,587 (실측)	44.1%	분포 변화 강건성 (선택)	EVA02 제안서
ConvNeXt V2-Tiny	`convnextv2_tiny.fcmae_ft_in22k_in1k_384`	27,887,259 (실측)	55.8%	V1 vs V2 비교 (최하위 우선순위)	EVA02 제안서
Swin-Tiny	`swin_tiny_patch4_window7_224`	약 27.5M (계산)	55%	Transformer 대안 (여유 시)	구조 후보
ResNet-50	torchvision IN-1k	23,563,355 (실측)	47.1%	생략 제안 추가	달파 제안서

EfficientNetV2-S는 torchvision(20.21M)과 timm(20.18M) 구현에 따라 조금 다름. TResNet-M(약 29M)도 후보로 검토했으나 우선순위가 낮아 제외. MaxViT-Tiny는 8장의 보류 후보 표 참고.

사전학습 가중치 통일 추가 정정

기존 제안서는 ConvNeXt-Tiny를 torchvision ImageNet-1k 가중치 기준으로 적었고, EVA02-S·ConvNeXt V2-T는 ImageNet-22k 가중치임. 이대로 비교하면 구조 차이가 아니라 사전학습 데이터 차이를 측정하게 됨. **CNN도 위 표의 22k 사전학습 가중치로 통일**할 것을 제안. 파라미터 수는 동일함.

앙상블 예산 예시

조합	합계	여유	출처
EVA02-S + ConvNeXt-T	49,595,286 (실측)	약 0.4M	EVA02 제안서
ConvNeXt-T + EfficientNetV2-S	약 48.0M	약 2M	추가 제안
EVA02-S + EfficientNetV2-S	41,966,470 (실측)	약 8M	EVA02 제안서
EfficientNetV2-S + ResNet-50	약 43.8M	약 6M	구조 후보

앙상블은 단일 모델이 한계에 닿은 뒤에만 검토. EVA02-S는 해상도를 바꾸면 위치 임베딩 크기가 달라져 파라미터가 조금 변하므로, 여유 0.4M 조합은 최종 해상도에서 꼭 다시 셀 것.

헤드 후보

ID	구조	헤드 파라미터 (ConvNeXt-T 기준)	도입 조건
C1	GAP + Linear	약 0.02M	기준선
C2	클래스 쿼리 27개 Cross-Attention (Self-Attention 제거, D=384)	약 2.09M	기준선 오류 분석에서 작은 물체·유사 상의 혼동이 확인될 때
C3	C2 + 멀티스케일 키/값 (stride 16+32)	약 2.24M	C2가 이기고 작은 액세서리 오류가 남을 때

정정 구조 후보 문서는 ConvNeXt-S를 "헤드를 붙이면 50M 초과"로 제외했으나, 선형 헤드는 약 49.47M으로 제한 안임. 50M을 넘는 것은 쿼리 헤드(+2M)를 붙일 때뿐.

4. 실험 로드맵

두 제안서의 STEP 번호를 통합함. 한 실험에서 Backbone·손실·해상도를 동시에 바꾸지 않음. 실험 ID 예: `S2 / EVA02-S / BCE / 378px`

STEP	실험	고정 조건	다음 단계로 가는 조건
1 기준선	ConvNeXt-T(22k) · BCE · 384 · 임계값 0.5. 소량 과적합 점검 후 전체 학습	라벨 매핑, split, seed, 학습 예산	파이프라인 정상 동작, 세 F1과 클래스별 TP/FP/FN 확보
2 Backbone	ConvNeXt-T vs EVA02-S (378px). 여유 시 DINOv2-S, ConvNeXt V2-T, ConvNeXt-S	손실·증강·epoch 동일. ViT만 layer-wise lr decay 허용	시드 변동보다 큰 차이가 날 때만 복잡한 쪽 채택
3 손실	BCE vs ASL (γ^-=4, γ^+=0, clip=0.05). 필요 시 DB Loss	채택한 Backbone·입력	희귀 클래스 재현율 개선, Micro·Image-wise F1 유지
4 해상도·전처리	384 vs 448 (ViT는 378 vs 448). 강제 resize vs 패딩 별도 비교	Backbone·손실	액세서리 클래스 F1 개선이 VRAM·시간 비용을 정당화할 때
5 임계값	공통 0.5 → 공통 최적값 → 제한적 클래스별 임계값	저장한 검증 확률 사용	희귀 클래스는 공통값 유지. Train 내부 홀드아웃으로 안정성 확인
6 헤드	C1 vs C2, 이후 C2 vs C3	Backbone·손실·해상도	여러 seed에서 반복되는 개선
7 최종 선정	상위 후보 여러 seed 재학습, 파라미터 실측. 필요 시 앙상블	선택 규칙 사전 기록	개선 폭·변동성·추론 시간 종합
8 제출 점검	오프라인 `predict.py`, JSONL 형식, ZIP 압축 해제 후 실행	공개 테스트는 형식 확인만	모든 이미지가 유효한 레코드 1개씩

5. 공통 학습 설정 (시작값)

항목	시작값	비고
입력	RGB 변환 → 종횡비 유지 resize → 384 정사각형 패딩	무작위 crop 사용 안 함 (잘린 물체의 라벨이 남는 문제)
증강	좌우 반전만	강한 증강은 기준선 뒤 별도 실험
손실	`BCEWithLogitsLoss`	학습 중 Sigmoid 중복 적용 금지
옵티마이저	AdamW + warmup + cosine, AMP	학습률·epoch·batch·weight decay는 팀 회의에서 확정
ViT 전용	layer-wise lr decay 0.65~0.75, drop path 0.1, 해상도는 14의 배수	`dynamic_img_size=True`로 위치 임베딩 보간
출력	Sigmoid → 임계값 → 클래스명 리스트 또는 `[]`	softmax·argmax·강제 top-1 금지
저장	best/last checkpoint, 설정, 검증 logits	임계값 실험은 저장한 logits로 재학습 없이 수행
제출 로딩	`pretrained=False` + `model.pt` 로드	인터넷 차단 상태에서 확인

6. 평가·선택 규칙

- Micro F1, Macro F1, Image-wise F1을 항상 함께 기록하고 클래스별 support·TP·FP·FN·Precision·Recall도 저장
- 공식 가중치 공지 전에는 임의의 "종합 점수"를 만들지 않음. 주요 지표와 보조 지표를 팀이 미리 정해 기록
- 공식 Val은 반복 사용할수록 낙관적으로 보이므로, 하이퍼파라미터 탐색은 Train 내부 홀드아웃을 우선 사용
- 개선 폭이 seed 변동 이하이면 더 복잡한 구조를 채택하지 않음
- 5,000장 규모를 현실적인 시간 안에 처리하지 못하는 모델은 탈락

7. 조교에게 확인할 질문

1. Fashionpedia 원본의 마스크·박스 주석을 학습에 써도 되는가? (검출·분할 기반 C6 여부 결정)
2. 학습에만 쓰고 추론에서 빼는 보조 헤드도 50M에 포함되는가?
3. Fashionpedia로 이미 학습된 공개 체크포인트를 초기값으로 써도 되는가?
4. 큰 교사 모델이나 외부 모델로 만든 의사라벨을 써도 되는가? (증류 C7 여부 결정)
5. 라벨이 있는 Examples 30장은 어떤 용도까지 허용되는가? (형식 확인만인지, 검증에 써도 되는지) 추가

8. 보류 후보

후보	보류 이유	재검토 조건
C6 검출·분할 후 합집합 (FashionFormer 등)	박스·마스크 사용 허용 여부 미확인, 구현 비용 큼	질문 1이 허용되고 단일 분류 모델이 한계에 닿을 때
C7 지식 증류	교사 모델 사용 허용 여부 미확인	질문 4가 허용되고 기준선이 확정된 뒤
MaxViT-Tiny 384 추가	약 31M으로 제한 안이나 window 크기에 따른 해상도 제약과 느린 학습 속도가 예상됨 (일반적 특성 기준, 직접 측정 아님). Codex가 "다른 완성형 backbone으로 교체" 안으로 추천	STEP 2에서 시간이 남고 ConvNeXt-T·EVA02-S 비교가 끝난 뒤
ConvNeXt-Small 단일 모델 추가	선형 헤드 약 49.47M으로 가능하나 쿼리 헤드·앙상블 여유가 없음. Codex는 "시간 안에 안정적으로 완성" 안으로 추천	STEP 2에서 단일 모델 상한을 확인하고 싶을 때
규칙 기반 후처리 ("X가 있으면 Y")	동시 등장은 오분류의 증거가 아니고 여러 사람이 섞일 수 있음	채택하지 않음

9. 근거 문서

- EDA_Report.md — 데이터 EDA 및 라벨 분포 분석 (2026-10-30)
- 달파프로젝트_EDA+모델제안.pdf — EDA와 선행연구에 기반한 패션 멀티라벨 분류 모델 제안
- 모델 구조 후보 — 패션 카테고리 태깅.pdf (2026-10-28)
- Transformer_Backbone_제안서_EVA02-Small.pdf — 예진 (2026-10-31)
- 선행연구: ConvNeXt (CVPR 2022), ConvNeXt V2 (CVPR 2023), EVA-02 (2024), DINOv2 (2024), ASL (ICCV 2021), DB Loss (ECCV 2020), Query2Label (2021), ML-Decoder (WACV 2023), Fashionpedia (ECCV 2020)