Transformer 계열 Backbone 제안서 (EVA02-Small 중심)

MAT4091 Fashion Category Tagging · 내부 검토용 · Oct 31, 2026 · @예진

핵심 제안

저는 팀 후보에 비어 있는 **Transformer(ViT) 계열 Backbone**을 맡아, 기존 CNN 후보와 같은 조건에서 비교하겠습니다. 주력은 **EVA02-Small**(21.75M)이고, 보조로 **DINOv2 ViT-S/14**(22.07M)와 **ConvNeXt V2-Tiny**(27.89M)를 둡니다.

1. **EVA02-Small**을 팀 STEP 2(Backbone 비교)에 CNN 대 Transformer 비교 축으로 추가한다.
2. **DINOv2 ViT-S/14**로 Train–Val 분포 차이와 Private Test 분포 변화에 대한 강건성 가설을 시험한다.
3. **ConvNeXt V2-Tiny**로 팀원의 ConvNeXt-Tiny(V1)와 V1 대 V2(FCMAE 사전학습 + GRN) 차이를 확인한다. 우선순위는 가장 낮다.
4. ViT 후보는 파라미터가 약 22M이라, 이후 Query 기반 Head나 CNN과의 앙상블 여유가 가장 크다. 예: EVA02-Small + ConvNeXt-Tiny = 49.60M.

표기는 팀 제안서를 따릅니다. **[EDA 관측]** = 팀 EDA 집계, **[선행연구]** = 공개 논문·모델 문서, **[제안/가설]** = 실험으로 검증할 의견. 이 문서의 어떤 수치도 F1 실측 결과가 아닙니다.

1. 제안 배경: 왜 Transformer 계열을 추가하나

현재 팀 후보 4개(ResNet-50, ConvNeXt-Tiny, ConvNeXt-Small, EfficientNetV2-S)는 모두 CNN입니다. 그래서 STEP 2의 결론이 "CNN 중 무엇이 낫나"로 좁아집니다. Transformer 계열을 하나 넣으면 "왜 이 구조 계열을 채택했는가"에 대한 근거가 생깁니다.

팀 EDA에서 확인된 사실 [EDA 관측]	이 제안과의 연결 [제안/가설]
Val의 shoe 비율이 Train보다 16.92%p 높음. Private Test 분포는 알 수 없음	대규모 자기지도·MIM 사전학습 특징이 분포 변화에 더 강한지 비교 (EVA02, DINOv2)
세로형 이미지 약 80%, 짧은 변 중앙값 682px	ViT는 위치 임베딩 보간으로 비정사각 입력 가능. 팀의 Resize vs Padding 비교에 참여
Val 양성 10장 미만 클래스 4개(tie 3, cape 5, umbrella 5, leg warmer 7)	사전학습이 강할수록 적은 예시로도 클래스를 구분할 수 있는지. 단, 이 클래스의 F1 차이는 변동이 커서 여러 시드로 판단
빈 정답 이미지 Train/Val 모두 0장	Backbone 선택만으로 해결되지 않음. 팀 공통 과제로 남김

주의: 위 오른쪽 열은 모두 가설입니다. ImageNet 성능이나 다른 데이터셋 결과가 이 과제의 F1 우위로 이어진다고 가정하지 않습니다.

2. 후보 모델과 50M 예산

제가 맡을 3개 모두 27클래스 Head를 붙여도 단일 모델로 50M의 56% 이하입니다. 파라미터 수는 `timm.create_model(name, num_classes=27)` 후 `sum(p.numel() for p in model.parameters())`로 직접 센 값입니다(2026-10-31, CPU, 가중치 미다운로드). 같은 방법으로 센 팀 후보 수치는 팀 제안서의 계산치와 일치했습니다.

모델 (timm 이름)	종류	총 파라미터 (27클래스)	50M 대비	사전학습 [선행연구]	기본 해상도	역할
EVA02-Small (`eva02_small_patch14_336.mim_in22k_ft_in1k`)	ViT, patch 14	21,754,395	43.5%	MIM(EVA-CLIP 특징 복원) on IN-22k → IN-1k fine-tune	336	**주력**
DINOv2 ViT-S/14 (`vit_small_patch14_dinov2.lvd142m`)	ViT, patch 14	22,066,587	44.1%	자기지도 on LVD-142M (라벨 없는 1억 4천만 장)	518	보조: 분포 변화 강건성
ConvNeXt V2-Tiny (`convnextv2_tiny.fcmae_ft_in22k_in1k_384`)	CNN	27,887,259	55.8%	FCMAE → IN-22k → IN-1k fine-tune	384	선택: V1 대 V2 비교
ConvNeXt-Tiny (팀 후보, 참고)	CNN	27,840,891	55.7%	IN-1k 지도학습 (torchvision)	224	비교 기준
ResNet-50 (팀 후보, 참고)	CNN	23,563,355	47.1%	IN-1k 지도학습	224	STEP 1 기준선

ViT의 위치 임베딩 크기는 입력 해상도에 따라 조금 달라집니다. 최종 제출 해상도에서 다시 세야 합니다.

앙상블 예산 예시 (실측 합산): EVA02-S + ConvNeXt-Tiny = 49,595,286 (여유 0.4M) · EVA02-S + ResNet-50 = 45,317,750 · EVA02-S + EfficientNetV2-S = 41,966,470 · EVA02-S + ConvNeXt V2-Nano = 36,754,502. 앙상블은 단일 모델이 한계에 닿았을 때만 검토합니다.

3. 제안 모델의 기술적 형태

팀 기준선과 같은 파이프라인에서 **Backbone만 교체**합니다. 다른 점은 ViT 전용 설정 세 가지뿐입니다.

입력 이미지 → RGB 변환 → Resize 또는 종횡비 유지 Pad (팀 규칙 동일) → **EVA02-Small** (14×14 패치 토큰 + Transformer 12층) → timm 기본 pooling → Linear(384→27) → Sigmoid → 임계값 → 클래스명 리스트 또는 []

- **Loss / 출력**: 팀과 동일. BCEWithLogitsLoss, `categories.txt` 순서 고정, 초기에는 무작위 Crop 없음.
- **해상도는 14의 배수로 맞춤**: patch 14라 팀 기준 320/384px를 그대로 쓰면 가장자리가 잘립니다. 320 → **322**(23×23 = 529 토큰), 384 → **378**(27×27 = 729 토큰)로 대응시키고, 픽셀 수 차이(약 1~3%)를 기록합니다. 기본 336(576 토큰)은 별도 기준점으로 둡니다.
- **위치 임베딩 보간**: 기본 해상도와 다른 입력과 세로형 비정사각 입력은 timm의 `dynamic_img_size=True` (또는 `img_size` 지정)로 위치 임베딩을 보간해 처리합니다.
- **학습률 설정 [제안/가설]**: ViT fine-tuning에서 흔히 쓰는 layer-wise lr decay(아래쪽 층일수록 학습률을 작게)를 0.65~0.75 범위에서 시작합니다. AdamW + warmup + cosine, drop path 0.1, AMP를 씁니다. 모두 시작값이며 최적값이라고 주장하지 않습니다. 단, STEP 2 공통 비교에서는 팀이 정한 학습 예산(epoch 수)을 똑같이 지킵니다.
- **비용 [제안/가설]**: ViT의 attention 계산량은 토큰 수의 제곱에 비례합니다. 336 → 448(1,024 토큰)이면 토큰은 1.78배지만 attention 부분은 약 3.2배입니다. 그래서 해상도별 VRAM과 이미지당 추론 시간을 반드시 같이 기록합니다.

4. STEP별 작업 순서 — 팀 로드맵 번호에 맞춤

팀 로드맵의 STEP 번호를 그대로 따르고, 제 작업은 주로 STEP 2에 들어갑니다. 한 실험에서 Backbone·Loss·해상도를 동시에 바꾸지 않는다는 팀 규칙도 그대로 지킵니다.

STEP	수행할 실험	고정 / 변경할 조건	판단 근거
STEP 1 기준선 공유	팀 ResNet-50 기준선 코드에 EVA02-Small을 연결. 27클래스 Head, 파라미터 실측, 이미지 수백 장으로 소규모 과적합 점검	팀의 라벨 매핑·Split·시드를 그대로 사용	파이프라인 정상 동작, Loss 감소, 이미지당 속도
STEP 2-a CNN 대 ViT	EVA02-Small vs ConvNeXt-Tiny vs ResNet-50. 322px(≈320)	BCE, 공통 임계값 0.5, 증강, 학습 예산 동일. ViT만 layer-wise lr decay 허용	3종 F1, 클래스별 TP/FP/FN, VRAM, 시간

STEP	수행할 실험	고정 / 변경할 조건	판단 근거
STEP 2-b 분포 변화 강건성	DINOv2 ViT-S/14를 같은 조건으로 추가. 모든 후보의 Train 내부 홀드아웃 F1과 공식 Val F1 격차를 비교	STEP 2-a와 동일	격차가 일관되게 작은 Backbone이 있는가 (여러 시드)
STEP 2-c (선택) V1 대 V2	ConvNeXt V2-Tiny vs ConvNeXt-Tiny	STEP 2-a와 동일	사전학습 차이만으로 의미 있는 이득이 있는가
STEP 3 Loss	상위 Backbone에서 BCE vs ASL (팀 공통 실험에 합류)	채택한 Backbone·입력 고정	희귀 클래스 Recall과 FP, Macro/Micro F1
STEP 4 해상도·전처리	ViT는 322 → 378 → 선택적으로 448 (14의 배수). Resize vs Padding은 별도 비교	Loss·Backbone 고정	작은 클래스 F1 vs 토큰 수 증가에 따른 VRAM·시간
STEP 5 임계값	팀 규칙대로. 공통 임계값 후 제한적 클래스별 임계값	공식 Val 과사용 금지, Train 내부 예측 활용	F1 및 임계값 분산
STEP 6 구조 고도화	필요 시 (a) ViT 패치 토큰을 Query 기반 Head에 연결, 또는 (b) ViT + CNN 앙상블 (50M 이하)	Backbone·Loss·입력·학습 예산 고정	단일 모델 대비 개선 폭과 비용
STEP 7 최종 선정	상위 후보를 여러 시드로 재평가, 최종 해상도에서 파라미터 재측정	선택 규칙과 비교 기록	개선 폭/변동성/지연/안전 여유
STEP 8 제출 점검	`predict.py`가 인터넷 없이 `model.pt`에서 가중치를 읽는지 확인 (`pretrained=False` + 로드). 해상도·위치 임베딩 설정 포함	공개 테스트는 출력 형식만 검증	재현성과 평가 규정 준수

실험 표기는 팀 규칙을 따릅니다. 예: `STEP 2-a / EVA02-Small / BCE / 322px`.

5. 판단 기준

ViT가 같은 조건에서 뚜렷한 이득을 보이지 않으면, 더 단순하고 학습이 안정적인 CNN을 채택하는 것이 기본입니다.

관측되는 실험 결과	다음 선택
EVA02-S와 ConvNeXt-Tiny의 F1이 시드 변동 범위 안에서 같음	CNN 채택. ViT는 앙상블 후보로만 유지
EVA02-S가 Macro F1 또는 작은 클래스 F1에서 일관되게 우세	EVA02-S를 주 Backbone으로 STEP 3 이후 진행
DINOv2-S의 Train 내부 대비 공식 Val 격차가 일관되게 가장 작음	분포 변화 대비용 후보로 남기고, 앙상블에서 검토
ViT가 우세하지만 378px 이상에서 VRAM·시간이 감당 안 됨	322~336px에 고정하고 해상도 이득은 CNN에서 확보
ViT와 CNN의 오류 클래스가 서로 다름 (FP/FN 패턴 불일치)	STEP 6에서 ViT + CNN 앙상블 시험 (예: 49.60M)
ConvNeXt V2-T가 V1 대비 이득 없음	STEP 2-c 종료, 팀 후보 유지

6. 리스크와 대응

리스크	대응
ViT는 학습률 등 설정에 민감해서, 같은 학습 예산에서 CNN보다 불리하게 보일 수 있음	layer-wise lr decay만 추가하고, 설정 차이를 표에 명시. 튜닝은 Train 내부 분할에서만
해상도를 올리면 attention 비용이 토큰 수의 제곱으로 증가	해상도별 VRAM·시간 기록, 필요 시 gradient checkpointing
14의 배수 해상도 때문에 CNN과 입력 크기가 완전히 같지 않음	322/378로 대응시키고 픽셀 수 차이(약 1~3%)를 명시
tie·cape·umbrella·leg warmer는 Val 양성이 3~7장이라 한 번의 비교로 우열을 말할 수 없음	최종 후보는 여러 시드 평균과 변동 범위로 판단
timm `pretrained=True`는 실행 시 인터넷에서 가중치를 받음	제출본은 `pretrained=False` + `model.pt` 로드. STEP 8에서 네트워크를 끊고 확인
GPU 서버를 여러 명이 공유	ViT 실험은 배치 크기·해상도를 미리 알려 사용 시간을 조율

팀에 필요한 것: 팀 기준선 코드, 고정된 Split·시드, STEP 2 공통 학습 예산(epoch 수) 확정.

참고자료

팀 자료: 팀 제안서 「EDA와 선행연구에 기반한 패션 멀티라벨 분류 모델 제안」의 EDA 수치 [D1]와 STEP 로드맵, MAT4091 과제 명세 [A1].

공개 선행연구 (arXiv 주소, 본문 수치는 각자 원문으로 재확인 필요):

- Fang et al. (2024), EVA-02: A Visual Representation for Neon Genesis
- Oquab et al. (2024), DINOv2: Learning Robust Visual Features without Supervision
- Woo et al. (CVPR 2023), ConvNeXt V2: Co-designing and Scaling ConvNets with Masked Autoencoders
- Dosovitskiy et al. (ICLR 2021), An Image is Worth 16x16 Words (ViT)
- Bao et al. (ICLR 2022), BEiT — layer-wise lr decay fine-tuning 설정의 출처
- Ridnik et al. (ICCV 2021), Asymmetric Loss · Ridnik et al. (WACV 2023), ML-Decoder

파라미터 실측: timm (pytorch-image-models), `num_classes=27`, 2026-10-31.