패션 카테고리 태깅 모델 구조 후보 보고서

Oct 28, 2026

개요

목적. MAT4091 IC-PBL "Fashion Category Tagging"(Fashionpedia 27개 카테고리 이미지 단위 멀티라벨 분류, 추론 파라미터 합계 50M 이하)에서 팀 회의에 내놓을 모델 구조 후보와 실험 계획을 제안한다.

핵심 제안.

- ConvNeXt-T(약 27.8M) 기준선(C1)에서 시작해, 클래스 쿼리 기반 Cross-Attention 헤드(C2), 멀티스케일 키/값(C3) 순으로 한 모듈씩 확장한다. 세 후보 모두 약 30M 이하라 50M 예산에 여유가 있다.
- 후보는 병목 가설(작은 액세서리, 비슷한 상의 클래스 혼동, 희귀 클래스와 임계값)에 하나씩 대응시켜 설계했다.
- 손실→해상도→임계값→헤드 순으로 한 번에 한 가지만 바꿔 원인을 분리한다. C4~C7은 앞 단계에서 해결되지 않은 병목이 있을 때만 진행한다.

유의점. Fashionpedia 27클래스 이미지 단위 태깅을 다룬 논문은 찾지 못했다. 본 보고서의 수치는 선행연구 기반 가설과 계산 추정치이며, 실험으로 확인하기 전까지 성능 향상을 주장하지 않는다.

팀 결정이 필요한 사항. (1) 실험 세팅(옵티마이저·에포크 등)과 주요 선택 지표, (2) 조교에게 확인할 규정 질문 4가지(§7), (3) C4~C7 중 실제로 진행할 후보.

1. 요약

선행연구와 배경 정리에서 나온 병목 가설(작은 액세서리, 비슷한 상의 클래스 경계, 임계값과 Macro F1)을 기준으로 후보를 7개로 좁혔다. **후보 ID(C1~C7)는 구조의 이름이고, 손실 함수와 입력 해상도는 실험 설정으로 분리해** `C1-BCE-384` 처럼 실험 ID로 기록한다. 아래 파라미터는 timm 공식 결과표에서 분류기(1000클래스)를 뺀 백본 수치와 헤드 직접 계산값을 더한 추정치다.

후보 (구조)	구조	추정 파라미터	겨냥하는 병목	상태
C1	ConvNeXt-T + GAP + 선형	약 27.8M	기준선	가장 먼저 구현
C2	ConvNeXt-T + 클래스 쿼리 기반 Cross-Attention 헤드(Self-Attention 제거, stride 32, D=384)	약 29.9M	클래스별 영역 집중	C1 다음

후보 (구조)	구조	추정 파라미터	겨냥하는 병목	상태
C3	C2 + 멀티스케일(stride 16+32) 키/값	약 30.1M	작은 액세서리	C2가 이기고 작은 클래스 오류가 남을 때
C4	Swin-T + C2의 헤드	약 29.6M	백본 계열 비교	여유 있을 때
C5	EfficientNetV2-S + ResNet-50 앙상블	약 43.8M	분산 감소, 임계값 안정성	후반
C6	분할·검출 후 카테고리 합집합	아키텍처별로 분리 (37.7~45.9M)	작은 객체	조교 확인 후에만
C7	큰 교사 모델 증류 → C1 학생	학생 약 27.8M	데이터 부족	마지막

실험 ID	구조	해상도	손실
C1-BCE-384	C1	384	BCE
C1-ASL-384	C1	384	ASL
C1-(더 나은 손실)-448	C1	448	위에서 선택
C2-(손실)-(해상도)	C2	앞 단계에서 고정	앞 단계에서 고정

첫 실험 추천 순서: C1-BCE-384 → C1-ASL-384 → 해상도 비교 → 임계값 절차 → C2 → C3. 이 순서는 "어디서 얼마나 올랐는지"가 한 칸씩 분리되도록 짠 것이다. 아래 모든 기대 효과는 가설이며 실험으로 확인해야 한다.

2. 설계 원칙 — 병목 가설에서 구조로

구조를 먼저 고르지 않고, 병목 가설마다 그것을 겨냥하는 모듈을 하나씩 대응시켰다. 가설은 모두 EDA와 검증셋 오류 분석으로 확인해야 하는 상태다.

병목 가설	근거(선행연구)	대응 모듈	후보
작은 액세서리(안경, 시계, 장갑, 양말 등)가 특징 맵에서 사라진다	Fashionpedia 작은 객체 AP 17.3 vs 큰 객체 50.0	고해상도 입력, stride 16 특징 사용	C1 해상도, C3

병목 가설	근거(선행연구)	대응 모듈	후보
비슷한 상의 클래스끼리 헷갈린다 (shirt/top/sweater/cardigan/jacket/coat)	Fashionpedia 오류 분석: 같은 상위 범주 내 혼동을 제거하면 AP 0.791→0.912	클래스별 쿼리 헤드, 보조 상위범주 헤드	C2, C3
음성이 양성보다 훨씬 많아 희귀 클래스가 묻힌다	ASL, DB loss	ASL(γ-=4, m=0.05), 필요하면 DB loss	전 후보
임계값 하나로는 Macro F1이 낮다	F1=2TP/(2TP+FP+FN), 희귀 클래스 민감	클래스별 임계값(검증셋에서만 결정)	전 후보
숨겨진 평가셋이 검증셋과 다를 수 있다	과제 명세, FashionFail 분포 변화 실험	별도 실험으로 비교할 증강(자르기 + 큰 스케일 지터), EMA	전 후보
라벨 누락	단일 양성 라벨 방법들	데이터에서 누락이 확인될 때만 SPLC 등	조건부

선택 기준 세 가지. (1) 한 번에 하나만 바꿔서 원인을 분리할 수 있을 것, (2) 50M 이하 합계를 규정 질문 없이 만족할 것, (3) 추론이 폴더 단위 이미지 처리에서 감당 가능할 것.

3. 파라미터 예산

백본 수치는 timm 공식 결과표(results-imagenet.csv)의 param_count에서 ImageNet 분류기(특징차원×1000+1000)를 뺀 값이다. 헤드는 아래 식으로 직접 계산했다. 실제 제출 전에는 `sum(p.numel() for p in model.parameters())`로 반드시 다시 확인한다.

백본	분류기 포함(timm)	분류기 제외	출력 채널
ConvNeXt-T	28.59M	27.82M	768
ConvNeXt-S	50.22M	49.45M	768
ResNet-50	25.56M	23.51M	2048
ResNet-101	44.55M	42.50M	2048
Swin-T	28.29M	27.52M	768
ViT-S/16	22.05M	21.66M	384

백본	분류기 포함(timm)	분류기 제외	출력 채널
EfficientNetV2-S	21.46M	20.18M	1280

헤드 계산식. GAP+선형은 C×27+27. 쿼리 헤드는 입력 투영 C×D+D, 학습 쿼리 27×D, 교차 어텐션 $4D^2+4D$, FFN(확장 비율 4) $8D^2+5D$, 정규화 6D, 클래스별 출력 27×D+27이다. 자기 어텐션은 넣지 않는다(ML-Decoder 방식).

헤드	입력	파라미터
GAP+선형	ConvNeXt-T (768)	0.02M
GAP+선형	ResNet-50 (2048)	0.06M
쿼리 헤드 D=256	ConvNeXt-T	1.00M
쿼리 헤드 D=384	ConvNeXt-T	2.09M
쿼리 헤드 D=512	ConvNeXt-T	3.57M
쿼리 헤드 D=768	ConvNeXt-T	7.72M
쿼리 헤드 D=384, 멀티스케일(384+768채널)	ConvNeXt-T	2.24M
쿼리 헤드 D=384	ResNet-50	2.58M

결론적으로 헤드는 총량에서 작은 비중이다. ConvNeXt-T는 어떤 헤드를 붙여도 40M 이하라 10M 이상 여유가 남는다. ConvNeXt-S는 백본만으로 49.45M이라 헤드를 붙이면 50M을 넘기므로 후보에서 제외했다. 이 수치는 문서의 가정에 따른 추정이며, 어텐션 구현·정규화 층 수·편향 여부에 따라 달라진다. 확인할 것: (1) 실제 추론에 쓰는 모델 전부를 합산해 50M 이하인지(앙상블은 구성원 합계), (2) 학습 전용 보조 헤드가 제한에 포함되는지(§7 질문), (3) C6는 서로 다른 논문의 수치를 하나의 구조처럼 비교하지 말고 아키텍처별로 분리해 계산할 것.

4. 후보 구조 상세

C1. ConvNeXt-T + GAP + 선형 (기준선)

- **흐름(384 입력 기준):** 이미지 → ConvNeXt-T(12×12×768) → GAP → 선형(768→27) → 시그모이드 → 클래스별 임계값
- **파라미터:** 약 27.8M
- **장점:** 가장 단순하고 빠르다. 다른 후보의 비교 기준이 된다. CAM을 그릴 수 있어 오류 이미지 분석에 쓸 수 있다(모델이 올바른 물체를 보았다는 증명으로는 쓰지 않는다).
- **단점:** GAP이 작은 물체의 신호를 평균으로 희석할 수 있다(가설).

- **검증할 가설:** 동일 조건에서 BCE→ASL이 Macro F1을 올리고, 해상도 증가가 작은 클래스의 F1을 올린다.

C2. ConvNeXt-T + 클래스 쿼리 기반 Cross-Attention 헤드 (Self-Attention 제거)

- **이름에 대하여:** 이 헤드는 어느 논문의 재현이 아니라 직접 구성한 것이다. Query2Label(라벨 임베딩을 쿼리로 쓰는 디코더)와 ML-Decoder(자기 어텐션 제거, 그룹 디코딩)는 설계 동기를 제공한 선행연구로만 인용한다. 자기 어텐션 제거는 ML-Decoder 쪽에 더 가깝다.
- **흐름(384 입력):** 이미지 → ConvNeXt-T(12×12×768, **144 토큰**) → 입력 투영(768→384) → 27개 학습 쿼리가 교차 어텐션 → FFN → 클래스별 로짓. 448 입력이면 14×14, 196 토큰이다.
- **파라미터:** 약 29.9M (D=384, 헤드 2.09M, FFN 확장 비율 4 가정). 어텐션 구현, 정규화 층 수, 편향 사용 여부에 따라 달라진다. 어텐션 헤드 수·드롭아웃·잔차 연결도 구현 때 확정해 기록한다.
- **장점:** 클래스마다 자기 위치를 보므로 시계·장갑 같은 국소 클래스에 유리할 수 있다(가설). 교차 어텐션의 토큰 관련 연산은 27×토큰수×D라서 ViT 자기 어텐션(O(N²))보다 싼다.
- **단점:** 학습이 GAP보다 불안정할 수 있다. 작은 클래스는 stride 32 토큰에 이미 정보가 없을 수 있다.
- **검증할 가설:** 같은 손실·해상도에서 C1보다 세 지표와 상의 클래스 혼동이 개선된다. ML-Decoder의 COCO 결과(GAP 대비 +1.1 mAP, TResNet-M)는 이 프로젝트에서 재현된다는 보장이 아니다.

C3. C2 + 멀티스케일 키/값

- **흐름(384 입력):** stride 16(24×24×384, 576 토큰)과 stride 32(12×12×768, 144 토큰)를 각각 D 차원으로 투영해 스케일 임베딩을 더하고 하나의 키/값 집합(**720 토큰**)으로 합친다 → 27 쿼리 교차 어텐션 → FFN → 로짓. 448 입력이면 784+196=980 토큰이다. **C2와 C3 비교는 같은 해상도에서만 한다.** 코드에서는 "stage 3/4"라는 이름이 아니라 timm의 특징 출력 정보로 실제 stride와 채널 수를 확인해 기록한다.
- **파라미터:** 약 30.1M (D=384)
- **장점:** 해상도를 키우지 않고도 작은 액세서리가 보이는 특징을 쓸 수 있다(가설). 어텐션 점수 행렬(27×720)은 작지만, 토큰이 늘면 키/값 투영과 특징 추출 비용도 늘어난다. 파라미터 수와 추론 비용은 별개이므로 추론 시간을 따로 재야 한다.
- **단점:** 구현이 C2보다 복잡하다. 다른 논문에서 차용한 아이디어라 논문에 이 정확한 조합의 결과는 없다.
- **검증할 가설:** C2 대비 미리 정한 액세서리 클래스(안경·시계·장갑·양말·벨트)의 F1과 누락률이 개선된다.

C4. Swin-T + 쿼리 헤드

- **파라미터:** 약 29.6M. C2와 헤드·손실이 같고 백본만 다르다.
- **목적:** CNN 계열과 Transformer 계열의 차이를 확인한다. Query2Label 논문에서는 Swin-L이 CvT-w24보다 낮게 나왔지만 규모가 다르다. 이 작은 규모에서는 실험해봐야 안다.

- **주의:** Swin-T는 창 크기(7) 때문에 입력 해상도를 바꾸면 포지션 바이어스 처리를 확인해야 한다. ViT-S(21.7M)는 토큰 수에 따라 자기 어텐션이 O(N²)라 448 입력(784 토큰)에서 느려진다.

C5. EfficientNetV2-S + ResNet-50 앙상블

- **파라미터:** 백본 20.18M + 23.51M + GAP 헤드 약 0.09M = 약 43.8M
- **목적:** 서로 다른 계열의 예측을 평균해 분산을 줄이고 임계값을 안정시킨다.
- **주의:** 같은 예산으로 ConvNeXt-T 하나를 쓰는 것과 비교해야 공정하다. 단일 모델이 다 진 뒤 남는 성능 향상을 노릴 때만 쓴다.

C6. 분할·검출 후 합집합 (조건부)

- **흐름:** FashionFormer 같은 인스턴스 모델이 찾은 객체의 카테고리를 합쳐 이미지 단위 태그로 바꾼다. R50 버전이 37.7M에서 43.8M(논문마다 다름), Facere는 45.9M.
- **전제:** Fashionpedia의 마스크·박스 주석을 학습에 쓰는 것이 허용되어야 한다. 허용 여부 확인 전에는 실험하지 않는다.
- **위험:** 약한 작은 객체 성능, 분포 변화에 취약(FashionFail), 구현·학습 비용이 큰 편.

C7. 증류 (마지막 단계)

- **흐름:** 큰 교사 모델(제출물에 포함되지 않음) → C1 학생. 로짓 증류는 멀티라벨에서 효과가 작고(COCO +0.84), 의사라벨 생성이나 CAM 증류가 더 유망하다(CAM 79.00 vs 학생 74.09).
- **전제:** 교사 모델·의사라벨 사용이 규정상 허용되는지, 출처를 문서화할 수 있는지 확인해야 한다. CAM 증류는 GAP+선형 헤드에서만 바로 정의되므로 C1 학생에 적합하다(추정).

5. 공통 학습 레시피

후보들이 공유하는 설정이다. 후보 사이에서 바꿀 때는 하나씩만 바꾼다. 표의 "시작값"은 아직 확정된 값이 아니며, 비교 실험 전에 확정하고 기록해야 한다. 기본 해상도는 384, 기본 증강은 좌우 반전뿐이다.

항목	시작값	근거·메모
사전학습	ConvNeXt-T의 공개 ImageNet 파인튜닝 가중치 (정확한 timm 태그와 출처 기록)	ASL 논문의 사례는 ImageNet-21k 사전학습(TResNet-L 1k 86.6 → 21k 88.4)이고, 이 프로젝트의 체크포인트와는 별개다
입력 전처리	전체 이미지를 유지하는 리사이즈 또는 패딩, 해상도 384	과제는 이미지 전체의 카테고리 합집합을 예측한다
증강	좌우 반전만	라벨 의미가 보존되는 증강만. 다른 증강은 기준선 뒤에 하나씩 추가해 비교

항목	시작값	근거·메모
손실	BCE가 기준. ASL 시작 설정: γ-=4, γ+=0, clip(논문의 m)=0.05	이 조합은 합리적인 시작점이지 모든 구현의 보편적 기본값이 아니다. 구현의 실제 인자명과 선행연구 설정을 확인하고, 기준선과 같은 학습 조건에서 효과를 비교
초기 학습	몇 에포크 백본 고정 후 해제(선택, 효과는 가설)	헤드만 새로 초기화될 때 유리할 수 있다
EMA	기본은 끄기. 도입하면 EMA만 추가한 비교 실험으로	추론에 EMA 가중치를 쓰는지 명시
임계값	전역 임계값이 기준, 클래스별 임계값은 비교 대상. 학습 후 검증셋의 클래스별 예측 확률을 저장해 그 저장값으로 비교한다	공개 테스트 샘플로 튜닝 금지. 같은 검증셋에서 고른 임계값의 F1을 최종 성능처럼 반복 보고하면 과적합 위험이 있어, 선택 후 설정을 고정한다
확정 필요	옵티마이저, 학습률과 스케줄, 에포크 수, 배치 크기, 가중치 감쇠, 체크포인트 선택 기준, 시드	없으면 후보 간 비교와 재현이 안 된다

자르기 등 강한 증강은 별도 실험으로 분리한다. 분포 변화 가능성만으로 강한 증강을 기본 적용하면 이미지 내용과 라벨이 어긋날 수 있고, 증강이 분포 변화를 해결한다는 보장도 없다. 자른 뒤에 가방 등이 사라지면 원래 라벨과 맞지 않는다. FashionFail의 크롭 + 큰 스케일 지터 결과는 검출·분할 과제에서 나온 것이라 이미지 단위 태깅에서 안전하다는 근거가 아니다. 나중에 시험하려면 박스·마스크로 잘린 라벨을 갱신하거나 라벨이 보존되는 크롭만 허용해야 하므로, 주석 사용 규정 확인(§7)이 선행된다.

6. 실험 순서와 탈락 규칙

한 단계에서 한 가지만 바꾸고, 데이터 분할·사전학습 가중치·학습 설정·시드를 맞춰 비교한다. 손실과 해상도를 한꺼번에 바꾸지 않도록, 손실 비교를 먼저 하고 해상도 비교는 더 나은 손실을 고정한 뒤에 한다. 실험 ID는 §1의 표를 따른다.

단계	바꾸는 것	판단 지표	다음으로 넘어가는 조건
0	EDA: 클래스 빈도, 이미지당 라벨 수, 빈 라벨 비율, 분할 누수, 라벨 매핑 확인, 세 지표 계산 코드 고정	—	병목 가설 순위 확정
1	C1-BCE-384	세 지표, 빈 라벨 이미지 거짓 양성	파이프라인 동작
2	C1-ASL-384 (나머지 동일)	세 지표 + 클래스별 F1	동일 조건 BCE 대비 개선

단계	바꾸는 것	판단 지표	다음으로 넘어가는 조건
3	더 나은 손실 고정, 384 vs 448 (효과가 있을 때만 512)	액세서리 클래스 F1과 전체 지표	작은 클래스가 오르면 해상도 채택
4	임계값: 저장한 검증 확률로 전역 vs 클래스별 비교	세 지표 + 빈 라벨 이미지 거짓 양성	희귀 클래스는 양성 수가 적으면 전역값 유지
5	C2 vs C1 (같은 손실·해상도)	세 지표, 상의 클래스 혼동, 추론 시간	여러 시드에서 반복되는 개선
6	C3 vs C2 (같은 해상도, 384이면 720 vs 144 토큰)	미리 정한 액세서리 클래스 F1·누락률 + 전체 지표	C2가 효과가 있고 작은 클래스 오류가 남을 때만
7	조건부: 증강·EMA(각각 별도), C4, C5, C7, DB loss, 누락 손실	단계별	앞 단계에서 해결되지 않은 병목이 있을 때만

최종 후보는 여러 시드로 다시 학습해 평균과 변동폭을 함께 본다. 탐색 단계 실험까지 전부 여러 시드로 반복할 필요는 없다.

선택 기준 (제안). 세 지표가 서로 반대로 움직일 수 있어(예: Macro↑ Micro↓) "모든 지표가 동시에 오른 모델만 채택"은 쓰지 않는다. 최종 점수 기준과 가중치는 아직 공지되지 않았으므로, 공지 전까지 팀이 미리 정해 기록한다. (1) 주요 선택 지표: 과제가 명시하는 최종 평가 기준(없으면 팀 합의), (2) 보조 지표: 나머지 F1 지표, (3) 진단 지표: 클래스별 F1, 빈 라벨 이미지의 거짓 양성률, 추론 시간. 최종 선택은 점수 개선과 변동성, 계산 비용을 함께 본다.

탈락 규칙 (제안). (a) 주요 지표의 개선이 시드 변동폭 이하이면 복잡도를 올리지 않는다(기준값은 시드 분산을 본 뒤 정한다). (b) 추론이 느려 5,000장을 현실적인 시간 안에 처리하지 못하면 탈락. (c) 보조 지표가 크게 나빠지는 모델은 원인을 분석한 뒤 채택한다.

7. 위험·미확인·규정 질문

미확인 항목

- Fashionpedia 27클래스 이미지 단위 태깅을 보고한 논문은 찾지 못했다. COCO 멀티라벨 결과와 Fashionpedia 검출·분할 분석에서 간접적으로 추론한 것이다.
- 병목 순위(작은 액세서리 > 비슷한 상의 경계 > 임계값과 Macro F1 > 라벨 누락)는 가설이다. EDA와 검증셋 오류 분석 전에는 확정할 수 없다.
- 쿼리 헤드의 CAM 대체 분석 방법은 확인하지 못했다(어텐션 맵 시각화는 가능하지만 신뢰도는 별개).
- L2D(모델 증류)는 초록만 확인했다.
- 숫자(파라미터 추정치)는 계산이고 실제 코드로 재확인이 필요하다.

위험

- 숨겨진 평가셋이 검증셋과 다를 수 있다(과제 명시). 검증 점수에 과한 적합이 위험하다.
- 클래스별 임계값은 희귀 클래스에서 검증 표본이 적어 불안정할 수 있다. 클래스별 양성 수를 먼저 확인한다.
- 빈 라벨 이미지에 대한 평가를 한다고 했으므로 거짓 양성 없는 이미지 오류를 따로 본다.

조교에게 물어볼 규정 질문

1. Fashionpedia의 마스크·박스 주석을 학습에 써도 되는가? (C6, 보조 손실 여부를 좌우)
2. ~~학습에만 쓰고 추론에서 빼는 보조 헤드는 50M에 세는가?~~
3. Fashionpedia로 이미 학습된 공개 체크포인트를 초기값으로 써도 되는가?
4. 큰 교사 모델이나 의사라벨에 외부 모델을 써도 되는가(출처 문서화 조건)?

8. 근거 문서

- 멀티라벨 분류 선행연구 조사 — 패션 카테고리 태깅: ASL, Query2Label, ML-Decoder, Fashionpedia 등 논문별 수치와 출처
- 배경 지식 정리 — CNN부터 Query2Label까지: GAP, ASL, 어텐션, 쿼리 헤드의 개념 설명
- 논문 읽기 가이드: 논문을 읽으면서 확인할 항목
- timm 공식 ImageNet 결과표: 백본 파라미터 수치의 출처