데이터 분석 요약

MAT4091 Fashion Category Tagging · 1번(데이터·평가) · 클래스 수치는 labels.csv에서 직접 재집계

1. 한눈에 보기

	이미지 수	이미지당 평균 라벨	2개 이상 라벨 비율	빈 정답
Train 전체	45,622	2.96	79.5%	0
ㄴ 학습용 (train_inner)	43,197	2.91	-	0
ㄴ 내부 holdout (seed 42)	2,425	3.73	-	0
공식 Val	1,158	3.25	92.2%	0

- **클래스 불균형이 매우 크다.** Train 최다 shoe 23,954장, 최소 leg warmer 61장으로 약 393배 차이.
- **Val은 희귀 클래스가 너무 적다.** 양성 10장 미만 4개(tie 3, cape 5, umbrella 5, leg warmer 7), 30장 미만 9개. 클래스별 점수와 임계값이 몇 장에 크게 흔들린다.
- **Train과 Val의 분포가 다르다.** 예: shoe 비율 Train 52.5% vs Val 69.4%. Val 점수를 비공개 평가 점수로 볼 수 없다.
- **빈 정답 이미지가 하나도 없다.** 대상이 없는 사진에서의 오탐 성능은 이 데이터로 측정할 수 없다. 빈 예측 [] 출력은 구현하되 성능을 주장하지 않는다.

2. 이미지당 라벨 수

라벨 수	Train	%	Val	%
1	9,355	20.5	90	7.8
2	10,989	24.1	307	26.5
3	10,166	22.3	318	27.5
4	7,110	15.6	227	19.6
5	4,714	10.3	133	11.5
6	2,233	4.9	55	4.7
7	785	1.7	19	1.6
8	224	0.5	8	0.7
9	38	0.1	1	0.1
10 이상	8	0.02	0	0.00

중앙값 Train 3, Val 3. 최대 Train 11, Val 9. Val은 라벨이 더 많은 쪽으로 치우쳐 있다.

3. 자주 같이 나오는 쌍 (Train)

쌍	이미지 수	%	Jaccard
dress + shoe	10,787	23.6	0.34
top, t-shirt, sweatshirt + shoe	8,195	18.0	0.26
pants + shoe	8,065	17.7	0.29
top, t-shirt, sweatshirt + pants	6,673	14.6	0.31
shoe + bag, wallet	4,684	10.3	0.18
jacket + pants	4,608	10.1	0.30

동시 등장은 같은 사람의 착장 관계나 오분류를 뜻하지 않는다. 여러 사람이 한 사진에 있을 수 있다.

4. 내부 holdout 분할

- Train에서 2,425장(5.3%)을 떼어 체크포인트·임계값 선택에 쓰고, 공식 Val은 마지막 보고에만 쓴다.
- 희귀 클래스부터 채워서 모든 클래스가 holdout에 최소 8장 들어 있다(leg warmer 8장). 단순 무작위 5%였다면 3장 안팎이다.
- 그 결과 holdout은 평균 라벨 수가 3.73개로 Train(2.96)보다 약간 높다. holdout 점수와 공식 Val 점수는 숫자가 다를 수 있다.

5. 모델링에 주는 시사점 (가설, 아직 검증 안 함)

- Sigmoid 기반 멀티라벨 출력이 필수이고, 불균형 대응 손실(ASL 등)을 BCE와 비교할 근거가 있다.
- Macro F1은 희귀 클래스에 민감하고 Val 표본이 작아 불안정하다. 세 F1 지표와 클래스별 support를 함께 본다.
- 클래스별 임계값은 Val 양성이 적은 클래스에서 과적합 위험이 있어, 공통 임계값을 기준으로 비교한다.

6. 클래스별 분포 (Train 빈도 순)

클래스	Train	%	비율	Val	%	holdout
shoe	23,954	52.5		804	69.4	1,439
dress	18,666	40.9		506	43.7	934
top, t-shirt, sweatshirt	16,176	35.5		463	40.0	820
pants	12,347	27.1		313	27.0	730
jacket	7,742	17.0		179	15.5	503
bag, wallet	6,907	15.1		205	17.7	500
belt	6,667	14.6		159	13.7	490
shirt, blouse	6,115	13.4		102	8.8	421
skirt	5,034	11.0		162	14.0	332
glasses	4,848	10.6		130	11.2	405
watch	3,373	7.4		82	7.1	304
coat	3,085	6.8		103	8.9	243
headband, head covering, hair accessory	2,984	6.5		105	9.1	265
shorts	2,745	6.0		106	9.2	216
hat	2,514	5.5		74	6.4	254
tights, stockings	2,202	4.8		62	5.4	225
sweater	1,485	3.3		21	1.8	123
tie	1,455	3.2		3	0.3	142
sock	1,445	3.2		51	4.4	155
scarf	1,362	3.0		48	4.1	150
cardigan	1,101	2.4		12	1.0	114
jumpsuit	922	2.0		21	1.8	68
glove	757	1.7		18	1.6	83
vest	717	1.6		21	1.8	82
cape	152	0.3		5	0.4	16
umbrella	134	0.3		5	0.4	20
leg warmer	61	0.1		7	0.6	8

% 는 각 split의 전체 이미지 수 대비 비율. 막대는 Train 비율(shoe 52.5% = 100%). 다중 라벨이라 클래스별 양성 수의 합은 이미지 수보다 크다.

출처 구분

· 이 문서의 클래스 수·라벨 수·동시 등장·holdout 수치는 labels.csv를 직접 읽어 다시 센 값이다.

· 이미지 크기(짧은 변 중앙값 682px, 세로형 약 80%), 흑백 이미지 186장, 정확한 중복 0건은 팀 EDA 보고서(EDA_Report.md)의 값을 인용했고 여기서 다시 계산하지 않았다.

· 재인코딩·유사 이미지 중복과 이미지 내용의 라벨 정확성은 확인하지 않았다.