MAT4091 · Fashion Category Tagging · 독립 연구 제안서

EDA와 선행연구에 기반한 패션 멀티라벨 분류 모델 제안

27개 의류 카테고리 · 50M 이하의 추론 파라미터 · STEP별 검증 전략

> **핵심 제안**
> ① ResNet-50으로 재현 가능한 기준 성능을 만든다.
> ② ConvNeXt-Tiny가 성능·비용의 균형에서 이득을 주는지 확인한다.
> ③ 실제로 확인된 심한 클래스 불균형에 대해 ASL을 검증한다.
> ④ 공간적 오류가 실제로 나타날 때에만 Query 기반 Head를 추가한다. **50M을 전부 사용하는 것이 목표는 아니다.**

자료의 근거를 엄격히 구분함: [EDA 관측] = 사용자가 직접 분석한 집계 결과, [선행연구] = 공개 논문/모델 문서, [제안/가설] = 후속 실험으로 검증할 설계 의견. 본 보고서에 기재된 수치는 실제 모델의 F1 성능이 아니다.

Executive summary – 먼저 결정할 것

- **검증된 데이터 특성.** Training 45,622장, Validation 1,158장. shoe(23,954장)와 leg warmer(61장)의 Train 양성 수 차이는 **392.69배**이며, Val의 shoe 비율은 Train보다 **16.92%p 높다**.[D1]
- **평가상 위험.** Val 양성이 10장 미만인 카테고리가 4개(tie 3, cape 5, umbrella 5, leg warmer 7)다. 모든 클래스의 임계값을 Val에서 독립적으로 조정해도 안정적인 성능이 보장되지는 않는다.[D1]
- **빈 정답 문제.** Train/Val에는 정답 []가 **0장**, 30개 예시에는 **1장** 있다. 시스템은 반드시 빈 리스트를 출력할 수 있어야 하지만 현재 Val로는 빈 정답 이미지의 False Positive를 평가할 수 없다.[D1]
- **모델 제안.** 초기에는 이미지 → ImageNet 사전학습 Backbone → GAP → Linear(27) → Sigmoid → 임계값을 사용한다. 강한 정식 기준선과 구조 실험을 위한 확장 여유를 동시에 확보한다.[S3,S4]
- **연구 순서.** STEP 1 기준선 → STEP 2 Backbone 선택 → STEP 3 손실함수 → STEP 4 입력 해상도·전처리 → STEP 5 확률·임계값 → STEP 6 필요 시 공간적 Attention → STEP 7 재현성/최종 선택 → STEP 8 제출 체계.

1. 문제 정의: 원래 Fashionpedia와 수업 과제는 다르다

원래 **Fashionpedia**는 의류의 인스턴스 영역을 찾고 세부 속성을 인식하는 segmentation/attribute localization 연구이며, Attribute-Mask R-CNN을 기본 구조로 제안했다.

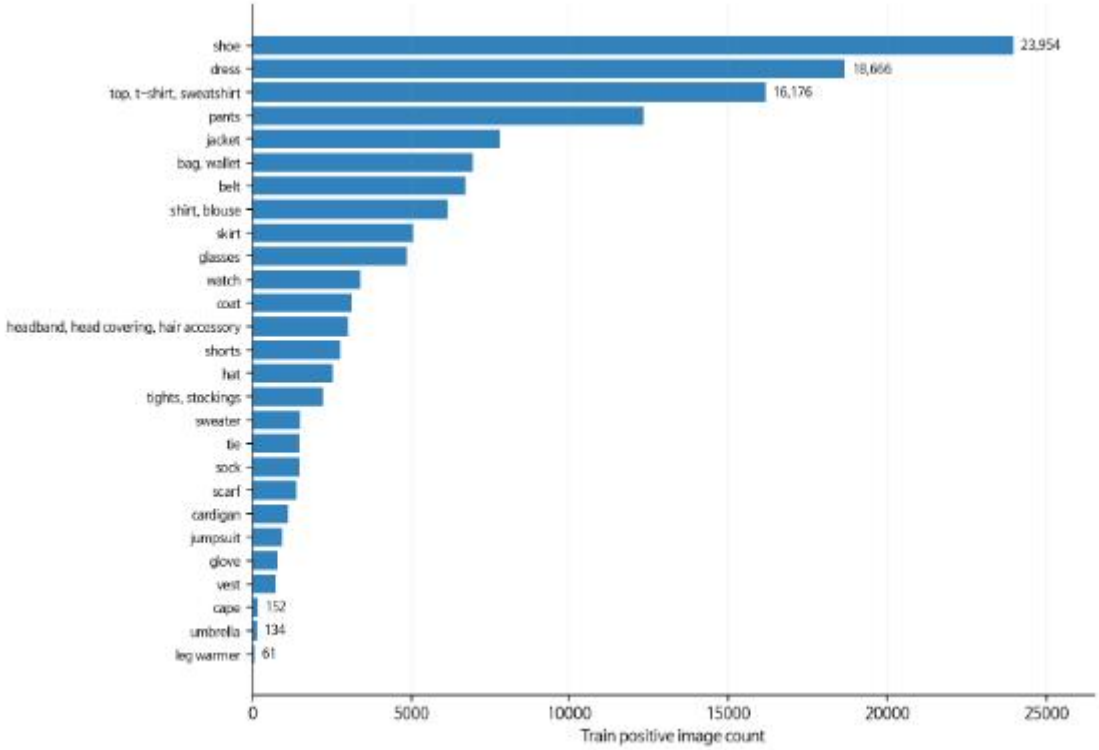
현재 MAT4091 과제는 한 이미지 내 여러 사람에게 나타나는 **27개 카테고리의 합집합을 이미지 수준 멀티라벨로** 예측한다. 박스·마스크를 출력할 필요가 없다.

과제 요구	반드시 지킬 조건	설계 영향
출력	27개 클래스의 정확한 이름을 리스트로 반환	클래스별 로짓 27개, Softmax가 아닌 Sigmoid
다중 라벨	한 이미지에 0개 이상 정답, 여러 인물의 합집합	하나의 클래스만 강제하는 Argmax 금지
빈 정답	타깃이 없다면 []	모든 확률이 기준 미만이면 빈 리스트 허용
예산	최종 예측에 쓰이는 전체 모델 합계 ≤ **50,000,000** 파라미터	Backbone + Head + 앙상블 구성 요소 모두 포함
검증	Micro / Macro / Image-wise F1	세 지표 및 클래스별 오류를 함께 보고
재현성	로컬/오프라인 추론, JSONL 출력	전처리·임계값·라벨 매핑까지 코드에 고정

원 논문의 Mask AP나 다른 데이터셋의 mAP를 **이 수업의 F1 예상값처럼 가져오지 않는다.** 본 보고서의 모델 선택은 해당 논문의 원리와 EDA가 보여준 데이터 특성을 연결한 *검증 가능한 제안*이다.

2. 직접 수행한 EDA: 어떤 사실이 모델을 좌우하는가

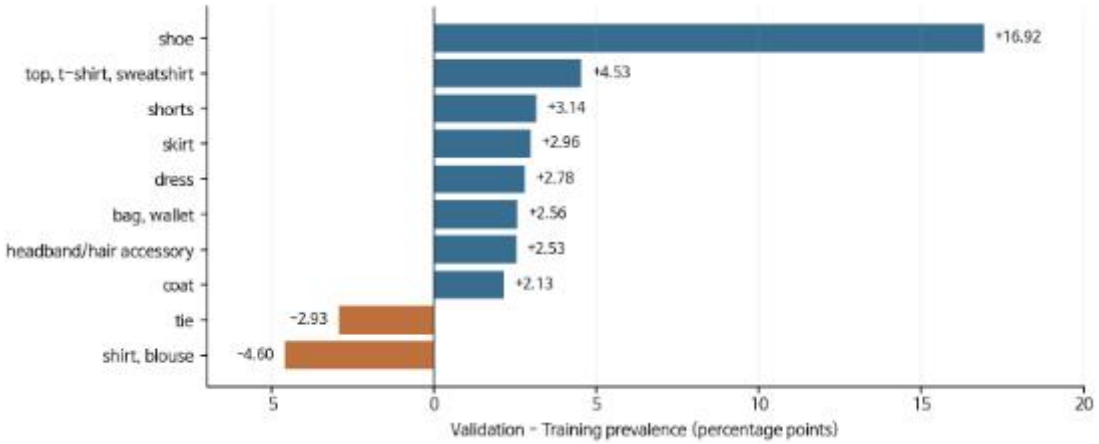
2.1 강한 클래스 불균형과 검증 분포 차이



클래스별 Train 양성 이미지 수

그림 1. Train의 27개 클래스별 양성 이미지 수. 다중 라벨이므로 클래스별 양성 수의 합은 이미지 수보다 클 수 있다. 출처: 사용자 EDA [D1].

핵심 클래스	Train 양성 / 비율	Val 양성 / 비율	해석
shoe	23,954 / 52.51%	804 / 69.43%	Val에서 **+16.92%p**
dress	18,666 / 40.91%	506 / 43.70%	흔한 양성 클래스
tie	1,455 / 3.19%	3 / 0.26%	Val에서 **-2.93%p**, 극소 검증 표본
cape	152 / 0.33%	5 / 0.43%	양성 학습·검증 사례 모두 적음
leg warmer	61 / 0.13%	7 / 0.60%	Train 최저 빈도
umbrella	134 / 0.29%	5 / 0.43%	신뢰성 낮은 클래스별 임계값 추정



Training 대비 Validation 클래스 등장률 변화

그림 2. Training과 Validation 사이 일부 클래스의 등장률 격차(Val−Train). 상위 격차를 발췌한 것으로 전체 27개 분포가 동일하다는 가정은 부적절하다. [D1]

해석. 가장 흔한 클래스와 희귀 클래스 간 격차는 실제로 관측되었다. 하지만 **BCE가 실패한다거나 ASL이 F1을 높인다는 것은 아직 관측되지 않았다.** 또한 Val의 분포가 달라졌다는 사실만으로 Private Test 분포를 예측할 수 없다.

2.2 다중 라벨, 종횡비, 빈 이미지의 의미

관측값	Training	Validation	설계 결과
평균 라벨 수/이미지	2.958	3.253	멀티라벨 손실·출력 필수
2개 이상 라벨이 붙은 이미지 비율	79.49%	92.23%	동시 예측의 중요성
빈 정답 이미지	**0**	**0**	빈 정답 관련 성능 검증 불가능
세로형 이미지	79.97%	79.27%	종횡비 보존 전처리 비교 필요
원본 짧은 변 중앙값	682px	682px	320/384/448px 실험 여지
그레이스케일 이미지	186장	0장	RGB 변환 일관성 검사

검증된 정확한 파일 중복(SHA-256)은 Train/Val 사이 **0건**, 실제 디코딩 실패도 **0건**이다. 단, 재압축·유사 이미지나 인물/촬영 출처의 중복까지 확인한 것은 아니며, 이미지 수준 라벨만으로 **액세서리의 픽셀 크기·가림·실제 시각적 혼동**은 알 수 없다.[D1]

2.3 Co-occurrence를 활용하되 과잉 해석하지 않는다

dress + shoe가 **10,787장**, jacket + pants가 **4,608장**, shirt, blouse + tie가 **1,402장**에서 동시에 관측된다.[D1] 이러한 수치는 다중 라벨을 학습해야 할 이유는 보여주지만, 특정 카테고리를 서로 **헷갈리는 오류**의 증거는 아니다. 여러 사람이 등장할 수 있어 같은 사람의 착장 관계라고 해석하는 것도 금물이다. 따라서 규칙 기반으로 "X가 있으면 Y를 출력"하는 후처리는 우선 제안하지 않는다.

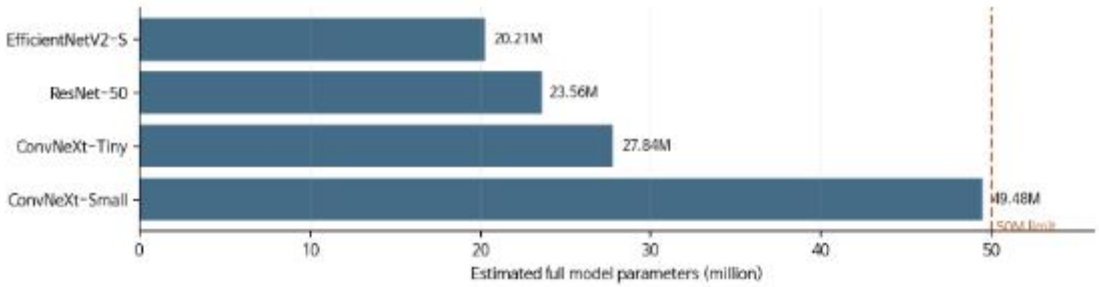
3. 선행연구에서 가져올 수 있는 실제 기술적 근거

연구	본래 연구 목표	이번 과제에 의미 있는 아이디어	주의점
Fashionpedia (ECCV 2020) [S1]	의류 영역 + 속성 인식	패션 특화 클래스 체계와 표현 학습	원본 박스·마스크 학습을 그대로 재현할 수 없음
FashionFormer (ECCV 2022) [S2]	Segmentation/attribute 통합	Query 기반 세부 패션 특징 모델링	결과는 이미지 수준 F1이 아님
ConvNeXt (CVPR 2022) [S3]	일반 시각 인식 Backbone	강력하고 재현 가능한 ConvNet 특징 추출	Fashionpedia 태깅에서의 우월성은 미검증
ASL (ICCV 2021) [S4]	멀티라벨 음성 지배 완화	음성 라벨이 많은 데이터에 대한 손실 대안	Macro F1 상승을 보장하지 않음
DB Loss (ECCV 2020) [S5]	Long-tail + 라벨 동시 등장	빈도와 공동 등장 관계를 고려한 가중 조절	구현·튜닝 복잡도 증가
Query2Label (2021) [S6]	라벨 Query로 관련 시각 특징 추출	클래스별 Cross-Attention Head	레퍼런스 mAP와 수업 F1은 다름
ML-Decoder (WACV 2023) [S7]	효율적인 쿼리 기반 분류 Head	GAP 대신 공간적 특징을 활용할 대안	실제 비용·이득을 직접 측정해야 함

이 문서의 **주요 연구 질문은 "가장 최신 구조가 무엇인가?"가 아니라 "관측된 병목을 해소할 구조인가?"**다. FashionFormer/Mask R-CNN의 원래 목적은 현재의 라벨 유형과 다르므로 처음부터 분할 모델을 학습하는 것보다 이미지 수준 분류용 Backbone을 먼저 검증하는 것이 현실적이다.

4. 50M 파라미터 예산: 분할 원칙과 후보 구조

4.1 동일한 27클래스 출력층으로 환산한 후보



파라미터 예산의 모델별 규모

그림 3. Torchvision이 공개한 ImageNet 1,000클래스 기본 구조의 파라미터 수에서 기존 Linear Head를 빼고 27클래스 Head를 더한 계산상 비교.[S8-S11] 실제 제출 객체의 파라미터는 반드시 다시 계수해야 한다.

27클래스 단일 모델(안)	Backbone+GAP+Linear 총량(계산치)	50M 한도 대비	권고 역할
EfficientNetV2-S	**20.21M**	40.4%	효율성 비교 후보
ResNet-50	**23.56M**	47.1%	단순하고 검증하기 쉬운 기준선
ConvNeXt-Tiny	**27.84M**	55.7%	주요 경쟁 Backbone
ConvNeXt-Small	**49.48M**	99.0%	거의 전액을 Backbone에 투자하는 상한 비교안

계산 예시. ConvNeXt-Tiny 28,589,128(1,000클래스 포함) − (768×1000+1000) + (768×27+27) = **27,840,891개**. ResNet-50은 25,557,032 − 2,049,000 + 55,323 = **23,563,355개**. 정확한 수치는 라이브러리·구현 버전에 따라 달라질 수 있다.[S8-S11]

4.2 어느 부분에 파라미터를 쓸 것인가?

안 A – 표현에 집중. ConvNeXt-Small(약 49.48M)에 간단한 27클래스 Head를 붙여 시각적 특징 추출 능력을 최대로 사용하는 방식. 단점은 확장 Head를 추가할 파라미터 여유가 거의 없고, 연산·메모리 비용도 커질 수 있다는 점.

안 B – 균형 배분(권장 실험안). ConvNeXt-Tiny 약 27.84M에 기본 Linear Head를 사용하고, 예측 오류가 공간적 특징 추출의 한계를 보이면 **별도 Class-aware Head에 약 1~4M 범위의 설계 예산**을 설정한다. 예산 1~4M은 **구현 전 목표 범위**일 뿐 검증된 파라미터 수나 성능 향상 수치가 아니다. Head를 만든 뒤 전체 합계를 재계산한다.

안 C – 경량성 우선. EfficientNetV2-S 약 20.21M을 활용하여 동일 품질에서 추론 지연과 메모리를 줄일 수 있는지 평가한다. 단, 파라미터가 적다는 이유만으로 실측 추론이 빠르다고 결론내리지 않는다.

결정 원칙: 50M 한도는 상한선이지 목표값이 아니다. 해상도를 224→384로 바꾸면 입력 픽셀 수가 약 **2.94배**, 224→448은 **4배**가 되지만 파라미터 수는 거의 동일하다. 따라서 **파라미터 수·GPU 메모리·추론 지연·F1**을 별도 축에서 함께 판단한다.

5. 제안 모델의 기술적 형태

가장 먼저 구현할 모델(기준선)

> 입력 이미지 → RGB 변환 → 종횡비 유지 Resize/Pad → ResNet-50 또는 ConvNeXt-Tiny → GAP → 27차원 Linear → 27개 Sigmoid 확률 → 고정 임계값 → 클래스명 리스트 또는 []

- **Loss:** BCEWithLogitsLoss. 학습 시 로짓에 다시 Sigmoid를 중복 적용하지 않는다.
- **Output:** 클래스 순서는 수업 제공 categories.txt를 기준으로 고정. 쉼표가 포함된 카테고리도 한 개의 클래스다.
- **Input:** 이미지 전체의 카테고리 합집합을 예측하므로 초기에 무작위 부분 Crop은 사용하지 않는다. 잘린 부분에 존재했던 물체의 라벨이 그대로 남는 문제가 생길 수 있다.
- **Augmentation:** 라벨 의미가 보존되는 좌우 반전 등을 간단하게 시작하고, 강한 증강은 독립 실험으로 분리한다.
- **계산:** 정사각형 강제 Resize와 종횡비 유지+Padding 사이의 우열은 실험으로 판단한다. 79~80%가 세로 이미지이므로 형상 왜곡과 유효 이미지 면적을 기록한다.

조건부 고도화: Label-aware Attention

Query2Label과 ML-Decoder는 클래스별 Query를 이용해 GAP가 한 벡터로 압축한 공간 특징을 더 적극적으로 활용하는 방법을 제안한다.[S6,S7] 이를 참고해 "27개 클래스 Query → 시각 토큰 Cross-Attention → 27개 로짓" 구조를 검토할 수 있다. **다만 EDA는 작은 액세서리의 실제 누락률이나 코트/재킷의 시각적 혼동을 확인하지 않았다.** 기본 모델에서 FP/FN을 관찰한 다음에 도입해야 인과적인 개선 실험이 된다.

6. STEP별 실험 로드맵 – 번호는 모델명이 아닌 작업 순서

STEP	수행할 실험	고정 / 변경할 조건	판단 근거
STEP 1 재현 가능한 기준선	ResNet-50 + BCE + 공통 임계값. 초기 320px를 예시 시작 설정으로 사용	라벨 매핑·Split·시드·학습 예산 기록	3종 F1, 클래스별 TP/FP/FN, 속도 확보
STEP 2 Backbone 비교	ConvNeXt-Tiny 대 ResNet-50	해상도·Loss·증강·학습 예산 동일	F1 개선이 복잡도/비용을 정당화하는지
STEP 3 Loss 비교	BCE vs ASL; 필요할 때 DB Loss	채택한 Backbone·입력 고정	희귀 클래스 Recall과 FP, 전체 Macro/Micro F1
STEP 4 전처리·해상도	320→384→선택적으로 448; 강제 Resize vs Padding은 **별도** 비교	손실·Backbone 먼저 고정	작은 클래스 F1, GPU VRAM, 시간
STEP 5 임계값 안정성	공통 임계값 기준 후 제한적인 클래스별 임계값	공식 Val 과사용 주의, Train 내부 예측 활용	F1 및 임계값 분산·과적합 위험
STEP 6 구조 고도화	필요하면 Label-aware Head 교체	Backbone·Loss·입력·학습 예산 고정	공간적 오류 개선 여부와 비용
STEP 7 최종 선정	상위 모델 여러 시드 재평가, 실제 전체 파라미터 측정	선택 규칙과 비교 기록	개선 폭/변동성/지연/안전 여유
STEP 8 제출 점검	오프라인 추론 ZIP + JSONL + 보고서	공개 테스트는 **출력 형식만 검증**	재현성과 평가 규정 준수

실험 표기: STEP 2 / ConvNeXt-Tiny / BCE / 320px처럼 **작업 순서 + 실제 모델명 + 손실 + 해상도**로 쓰면 된다. STEP은 단계 표시이며 공식 논문 모델의 이름이 아니다. 한 실험에서 **Backbone·Loss·해상도를 동시에 바꾸지 않는다.**

STEP 3을 우선 연구하는 이유: 불균형은 확인, 해결책은 미검증

ASL은 쉬운 음성 예시의 영향과 긍정·부정 라벨 간 비대칭성을 다루는 멀티라벨 손실로 제안되었다.[S4] DB Loss는 라벨 공동 등장과 긴 꼬리 분포를 함께 다룬다.[S5] leg warmer의 양성 61장에 대해 단순 역빈도 가중치를 무작정 크게 넣으면 False Positive나 학습 불안정이 커질 가능성이 있으므로, **BCE → ASL → 필요 시 DB Loss** 순서로 동일 조건 비교를 권고한다. 두 손실 모두 반드시 성공하는 전략은 아니다.

STEP 5가 필요한 이유: 27개 Threshold를 자유롭게 최적화하면 위험하다

tie는 Val 양성이 3개라 한 장의 예측 성공 변화로 Recall이 **33.3%p** 바뀐다(이는 F1 변화량과 같지 않음). cape/umbrella는 각각 5개다.[D1] Val을 모델·손실·해상도·임계값 선택에 반복 사용하면 성능이 낙관적으로 보일 수 있다. 우선 **공통 임계값 0.5**를 비교 기준으로 두되, 이 값이 최적이라고 주장하지 않는다. 클래스별 임계값은 Train 내부 홀드아웃/교차검증 예측으로 안정성을 확인하고, 양성 수가 너무 적은 클래스에는 공통값 또는 정규화된(shrunk) 값을 검토한다. Private Test나 Public Test 300장에 맞춰 조정하지 않는다.

7. 정확한 평가·오류 분석 설계

- **지표:** Micro F1, Macro F1, Image-wise F1을 동시 기록. 클래스별 support, TP, FP, FN, Precision, Recall, F1과 예측 라벨 수 분포도 보고한다.
- **선택 규칙:** 교수님이 최종 가중치를 발표하기 전에는 임의로 "공식 종합 점수"를 만들지 않는다. 팀이 사전 등록한 주요 지표와 보조 지표를 구분한다.
- **오류 질문:** 희귀 클래스에서 FN이 많은가? 특정 클래스만 FP가 높은가? 해상도를 높였을 때 실제로 달라졌는가? jacket/coat의 오분류는 예측으로 확인됐는가?
- **공식 Val:** 1,158장이고 분포가 Train과 다른 부분이 있다. 반복적인 하이퍼파라미터 탐색에는 Train 내부 개발 분할을 우선 활용해 Val 재사용을 줄인다.

- **Empty-set:** Train/Val에 빈 정답 0장이므로 빈 정답 검출 성능에 관한 일반화 주장은 금물. [] 출력 단위 테스트는 수행하고, 허용된 비공개 추가 음성 자료가 존재하면 출처·규칙을 확인한 후 별도 검증한다.
- **표준 오차:** 최종 후보는 최소 여러 시드에서 결과의 평균·변동 범위를 제시. 양성 3~7장짜리 클래스는 작은 F1 변동도 큰 불확실성을 갖는다.

8. 최종 권고와 의사결정 기준

지금 바로 선택할 것은 완성 모델이 아니라 '검증할 순서'다. 강한 불균형과 Train-Val 분포 차이는 수치로 확인됐으므로 손실함수와 검증 설계는 우선순위가 높다. 반면 작은 물체·가려짐·시각적 유사 클래스의 실제 오분류는 학습 후 오류 분석이 필요하므로 Head 복잡도를 선제적으로 증가시키지 않는다.

관측되는 실험 결과	다음 선택
ResNet-50와 ConvNeXt-Tiny 성능이 거의 같음	더 단순하거나 빠른 모델 선호
ASL이 희귀 클래스 F1을 개선하며 Micro/이미지 F1을 크게 해치지 않음	ASL 채택 검토
ASL이 FP만 늘리거나 시드 간 불안정	BCE 유지, DB Loss를 독립 추가 시험
고해상도 입력에서 이득이 비용을 정당화함	384/448 채택, 지연·VRAM 기록
특정 국소 클래스의 FN이 지속되고 Head 개선이 반복됨	공간적 Attention Head 검토
27개 클래스 임계값이 작은 표본에 따라 크게 변함	공통/그룹별 임계값, 안정성 우선
더 큰 Backbone이 의미 있는 이득 없이 비용만 큼	50M을 채울 필요 없이 작은 모델 제출

제출 전 확인: 최종 모델에 대해 sum(p.numel() for p in model.parameters())를 실제 실행한다. 전처리, Sigmoid, 임계값, 인덱스→클래스 매핑, 빈 리스트 처리, python predict.py --input_dir TEST_IMAGES --output predictions.jsonl를 모두 포함한다. 학습·검증 데이터 원본은 LMS 규정에 따라 비공개로 유지한다.

9. 참고자료 및 출처

사용자 EDA와 과제 규정

- **[D1]** EDA_Report.md, Model_Design_Input.md (2026-10-30 로컬 실행 집계). 이미지/개별 라벨 없이 사용자가 제공한 집계 수치만 인용.
- **[A1]** MAT4091 *Fashion Category Tagging* 과제 명세(2026 Fall, 업로드된 PDF): 목표, 평가, 50M 제한, 제출 규정.

공개 선행연구

- **[S1]** Jia et al. (ECCV 2020), *Fashionpedia: Ontology, Segmentation, and an Attribute Localization Dataset*. https://www.ecva.net/papers/eccv_2020/papers_ECCV/html/1203_ECCV_2020_paper.php
- **[S2]** Xu et al. (ECCV 2022), *FashionFormer: A Simple, Effective and Unified Baseline for Human Fashion Segmentation and Recognition*. https://www.ecva.net/papers/eccv_2022/papers_ECCV/html/2087_ECCV_2022_paper.php
- **[S3]** Liu et al. (CVPR 2022), *A ConvNet for the 2020s*. https://openaccess.thecvf.com/content/CVPR2022/html/Liu_A_ConvNet_for_the_2020s_CVPR_2022_paper.html
- **[S4]** Ridnik et al. (ICCV 2021), *Asymmetric Loss for Multi-Label Classification*. https://openaccess.thecvf.com/content/ICCV2021/html/Ridnik_Asymmetric_Loss_for_Multi-Label_Classification_ICCV_2021_paper.html
- **[S5]** Wu et al. (ECCV 2020), *Distribution-Balanced Loss for Multi-Label Classification in Long-Tailed Datasets*. https://www.ecva.net/papers/eccv_2020/papers_ECCV/html/1631_ECCV_2020_paper.php

- **[S6]** Liu et al., *Query2Label: A Simple Transformer Way to Multi-Label Classification*. https://arxiv.org/abs/2107.10834 · https://github.com/SlongLiu/query2labels
- **[S7]** Ridnik et al. (WACV 2023), *ML-Decoder: Scalable and Versatile Classification Head*. https://openaccess.thecvf.com/content/WACV2023/html/Ridnik_ML-Decoder_Scalable_and_Versatile_Classification_Head_WACV_2023_paper.html

파라미터 수 확인용 공개 모델 문서

- **[S8]** Torchvision, ResNet-50: https://docs.pytorch.org/vision/master/models/generated/torchvision.models.resnet50.html
- **[S9]** Torchvision, ConvNeXt-Tiny: https://docs.pytorch.org/vision/master/models/generated/torchvision.models.convnext_tiny.html
- **[S10]** Torchvision, ConvNeXt-Small: https://docs.pytorch.org/vision/main/models/generated/torchvision.models.convnext_small.html
- **[S11]** Torchvision, EfficientNetV2-S: https://docs.pytorch.org/vision/master/models/generated/torchvision.models.efficientnet_v2_s.html

이 문서는 사용자 EDA와 공개 논문을 독립적으로 연결한 **실험 전 모델 제안서**다. 특정 모델의 F1 성능, Private Test 분포, Attention·손실함수 개선 효과를 실측했다고 주장하지 않는다. 과제의 원문 요구사항·EDA 수치·공개 선행연구를 근거로 작성했으며, 모델 결과를 측정한 문서는 아니다.